

# Inferência Estatística I

## Métodos de estimação pontual

---



**Prof. Paulo Cerqueira Jr**

**Faculdade de Estatística - FAEST**

**Instituto de Ciências Exatas e Naturais - ICEN**

<https://github.com/paulocerqueirajr> 

# Métodos de estimação

# Introdução

- Vimos até então a propriedades dos estimadores.
- Contudo tais procedimentos não são métodos que possibilitam, em geral, a obtenção de estimadores em situações específicas.
- Vimos também que todo bom estimador deve ser função de uma estatística suficiente.
- Vamos considerar alguns métodos que possibilitam a obtenção de estimadores em situações específicas.
- São os seguintes:
  1. Método de máxima verossimilhança;
  2. Método dos momentos;
  3. Método de mínimos quadrados.

# Método da máxima verossimilhança

**Definição 1** O estimador de máxima verossimilhança (EMV) de  $\theta$  é o valor  $\hat{\theta} \in \Theta$  que maximiza a função de verossimilhança  $L(\theta \mid x)$ .

Tomamos como estimador aquele valor de  $\theta$  que torna a amostra observada a mais provável de ocorrer.


# Exemplo:

Sejam  $X_1, \dots, X_{10}$  uma a.a. de  $X \sim \text{Pois}(\theta)$ . Obtenha a estimativa de máxima verossimilhança para  $\theta$  se os valores amostrais foram:

3, 2, 2, 3, 4, 4, 1, 4, 1, 2

A função verossimilhança:

$$L(\theta) = \prod_{i=1}^{10} \frac{e^{-\theta} \theta^{x_i}}{x_i!}.$$



- O valor que maximiza  $L(\theta)$  é 2.34

# Propriedades do EMV:

1. Pode-se mostrar que o valor de  $\theta$  que maximiza a função de verossimilhança  $L(\theta \mid x)$ , também maximiza  $\ell(\theta; \mid) = \log L(\theta \mid x)$ .
2. No caso em que  $\theta$  é um intervalo da reta e  $\ell(\theta \mid x)$  é derivável, o EMV é dado pelo valor de  $\theta$  que satisfaz a equação de verossimilhança:

$$\ell'(\theta \mid x) = \frac{d}{d\theta} \ell(\theta \mid x) = 0.$$

3. Para verificar se  $L(\hat{\theta} \mid x)$  é um ponto de máximo, basta tomar:

$$\ell''(\theta \mid x) = \frac{d}{d\theta} \ell'(\theta \mid x) \Big|_{\theta=\hat{\theta}} < 0.$$

4. Em situações mais complicadas, a solução da equação de verossimilhança não pode ser obtida explicitamente, tem-se a necessidade de utilizar procedimentos numéricos.

# Exemplo

**Exemplo 1** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim \text{Pois}(\theta)$ . Obtenha a estimador de máxima verossimilhança para  $\theta$ .

# Exemplo


**Exemplo 2** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim N(\mu, 1)$ . Obtenha a estimador de máxima verossimilhança para  $\mu$ .



# Exemplo (suporte depende do parâmetro)

**Exemplo 3** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim U(0, \theta)$ . Obtenha a estimador de máxima verossimilhança para  $\theta$ .

# Exemplo




# Exemplo (Caso discreto)

**Exemplo 4** Temos uma caixa com bolas brancas e vermelhas. Sabe-se que a proporção  $\theta$  de bolas vermelhas na caixa é  $1/3$  ou  $2/3$ . Portanto,  $\Theta = \{1/3, 2/3\}$ . Uma amostra de 3 bolas, retiradas com reposição da caixa, apresentou bola vermelha na 1<sup>a</sup> extração e branca na 2<sup>a</sup> e 3<sup>a</sup> extrações. Obtenha uma estimativa de máxima verossimilhança para  $\theta$ .

# Exemplo (suporte depende do parâmetro)

**Exemplo 5** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim U(\theta - 1/2, \theta + 1/2)$ . Obtenha a estimador de máxima verossimilhança para  $\theta$ .

# Exemplo (suporte depende do parâmetro)



# EMV via Método do escore

- Em alguns casos, principalmente quando a verossimilhança está associada a modelos mais complexos, a função de verossimilhança não apresenta solução analítica explícita.
- Em tais casos, os estimadores de máxima verossimilhança podem ser obtidos por meio de métodos numéricos.
- Vamos denotar por  $U(\theta)$  a função escore, ou seja

$$U(\theta) = \frac{d}{dx} \log L(\theta \mid x),$$

- Determinamos o EMV através:

$$U(\hat{\theta}) = 0.$$

# EMV via Método do escore

- Expandindo  $U(\hat{\theta})$  em série de Taylor em torno de um ponto  $\theta_0$ , obtemos

$$0 = U(\hat{\theta}) \approx U(\theta_0) + (\hat{\theta} - \theta_0)U'(\theta_0).$$

- Dessa forma,

$$\hat{\theta} \approx \theta_0 - \frac{U(\theta_0)}{U'(\theta_0)}.$$

- Da equação anterior, temos o processo iterativo de *Newton-Raphson*:

$$\theta_{j+1} \approx \theta_j - \frac{U(\theta_j)}{U'(\theta_j)}$$

que é iniciado com o valor  $\theta_0$  e então o valor  $\theta_1$  é o obtido pela expressão anterior.

# Exemplo

**Exemplo 6** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X$ , com função densidade dada por

$$f(x \mid \theta) = \frac{1}{2} (1 + \theta x), \quad -1 \leq x \leq 1, \quad -1 \leq \theta \leq 1.$$

Determine o EMV para  $\theta$ .



# Exemplo

- Amostra de tamanho 100.
- Gerado uma amostra com  $\theta = 0.4$ , usando o método da função de distribuição.

```
1 # derivada 1:
2 u.theta <- function(par=par, dat=dat)
3   dv1 <- sum(dat/(1+(par*dat)))
4   return(dv1)
5 }
6
7 # derivada 2:
8 u.theta2 <- function(par=par, dat=dat)
9   dv2 <- -1*sum(dat^2/(1+(par*dat)))
10  return(dv2)
11 }
12
13 set.seed(12345678)
14
15 # Dados:
```

```
Iteração= 1   theta inicial= 0.1578034
theta novo= 0.4880783
Iteração= 2   theta inicial= 0.4880783
theta novo= 0.4661251
```

# Propriedades do EMV:

## Importante:

1. O EMV é sempre função de uma estatística suficiente;
2. O EMV é assintoticamente não viciado;
3. O EMV é invariante a transformações, ou seja, se  $\hat{\theta}$  é o EMV de  $\theta$ , então  $g(\hat{\theta})$  é o EMV de  $g(\theta)$ .

**Exemplo 7** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim \text{Ber}(\theta)$ . Obtenha a estimador de máxima verossimilhança para  $g(\theta) = \theta(1 - \theta)$ .

# Caso multiparamétrico

- Até então, estamos considerando situações em que a função de verossimilhança depende de somente um parâmetro.
- Quando a verossimilhança apresenta mais de um parâmetro, ou seja,  $\theta = (\theta_1, \dots, \theta_r)$ .
- Os EMV's  $(\hat{\theta}_1, \dots, \hat{\theta}_r)$  são obtidos como soluções das equações:

$$\frac{\partial}{\partial \theta_i} \log L(\theta \mid x), \quad i = 1, 2, \dots, r.$$

# Exemplo

**Exemplo 8** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim N(\mu, \sigma^2)$ , ambos desconhecidos. Obtenha o estimador de máxima verossimilhança para  $\theta = (\mu, \sigma^2)$ .

# Distribuição para grandes amostras

- Sob algumas condições temos que, para amostras grandes, o EMV de  $\theta$  satisfaz:

$$\sqrt{n}(\hat{\theta} - \theta) \stackrel{a}{\sim} N\left(0, \frac{1}{I_F(\theta)}\right),$$

e

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \stackrel{a}{\sim} N\left(0, \frac{(g'(\theta))^2}{I_F(\theta)}\right).$$

- Assim, os EMV's de  $\theta$ ,  $\hat{\theta}$ , e  $g(\theta)$ ,  $g(\hat{\theta})$ , são aproximadamente não-viciados e suas variâncias coincidem com os respectivos limites inferiores das variâncias dos estimadores não-viciados de  $\theta$  e  $g(\theta)$ .

# Exemplo

**Exemplo 9** Seja  $X_1, \dots, X_n$  uma a.a. de  $X \sim \text{Poisson}(\theta)$ . Obtenha o EMV de  $e^{-\theta}$  e sua distribuição assintótica.

**Solução:** Temos que  $\hat{\theta} = \bar{X}$ . Pela propriedade de invariância temos que

$$g(\hat{\theta}) = e^{-\bar{X}}.$$

que é o EMV para  $e^{-\theta}$ . A distribuição assintótica é dada por

$$\sqrt{n}(e^{-\bar{X}} - e^{-\theta}) \stackrel{a}{\sim} N(0, \theta e^{-2\theta}).$$

# Verossimilhanças para amostras independentes

- Quando temos duas amostras independentes de populações que dependem de um parâmetro  $\theta$ ,  $X_1, \dots, X_n, Y_1, \dots, Y_m$ , a função de verossimilhança pode ser escrita como

$$L(\theta \mid \mathbf{x}, \mathbf{y}) = L(\theta \mid \mathbf{x}) \times L(\theta \mid \mathbf{y})$$

- A função de log verossimilhança é dada por

$$\ell(\theta \mid \mathbf{x}, \mathbf{y}) = \log L(\theta \mid \mathbf{x}, \mathbf{y}) = \log L(\theta \mid \mathbf{x}) + \log L(\theta \mid \mathbf{y}) = \ell(\theta \mid \mathbf{x}) + \ell(\theta \mid \mathbf{y})$$

# Exemplo

**Exemplo 10** Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim N(\mu, 4)$  e  $Y_1, \dots, Y_m$  uma a.a. de  $Y \sim N(\mu; 9)$ , duas amostras independentes. Obtenha o EMV de  $\mu$ .

A verossimilhança conjunta é dada por

$$\begin{aligned} L(\mu, \mathbf{x}, \mathbf{y}) &= L(\mu, \mathbf{x}) \times L(\mu, \mathbf{y}) \\ &= \left( \frac{1}{2\sqrt{2\pi}} \right)^n e^{-\frac{1}{8} \sum_{i=1}^n (x_i - \mu)^2} \times \left( \frac{1}{3\sqrt{2\pi}} \right)^m e^{-\frac{1}{18} \sum_{i=1}^m (y_i - \mu)^2} \\ &= \left( \frac{1}{2\sqrt{2\pi}} \right)^n \left( \frac{1}{3\sqrt{2\pi}} \right)^m e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{8} - \sum_{i=1}^m \frac{(y_i - \mu)^2}{18}} \end{aligned}$$

Logo, o logaritmo da verossimilhança é dado por

$$l(\mu, \mathbf{x}, \mathbf{y}) = n \log \left( \frac{1}{2\sqrt{2\pi}} \right) + m \log \left( \frac{1}{3\sqrt{2\pi}} \right) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{8} - \sum_{i=1}^m \frac{(y_i - \mu)^2}{18}$$



# Exemplo

Tomando a derivada com relação a  $\mu$ , temos:

$$\begin{aligned}\frac{\partial l(\mu, \mathbf{x}, \mathbf{y})}{\partial \mu} &= -\sum_{i=1}^n \frac{2(x_i - \mu)(-1)}{8} - \sum_{i=1}^m \frac{2(y_i - \mu)(-1)}{18} \\ &= \sum_{i=1}^n \frac{(x_i - \mu)}{4} + \sum_{i=1}^m \frac{(y_i - \mu)}{9}\end{aligned}$$

Igualando a zero, temos:

$$\begin{aligned}\sum_{i=1}^n \frac{(x_i - \hat{\mu})}{4} + \sum_{i=1}^m \frac{(y_i - \hat{\mu})}{9} &= 0 \\ \frac{1}{4} \sum_{i=1}^n X_i - \frac{n}{4} \hat{\mu} + \frac{1}{9} \sum_{i=1}^m Y_i - \frac{m}{9} \hat{\mu} &= 0 \\ \hat{\mu} \left( \frac{n}{4} + \frac{m}{9} \right) &= \frac{1}{4} \sum_{i=1}^n X_i + \frac{1}{9} \sum_{i=1}^m Y_i \\ \hat{\mu} &= \frac{\frac{1}{4} \sum_{i=1}^n X_i + \frac{1}{9} \sum_{i=1}^m Y_i}{\frac{n}{4} + \frac{m}{9}}\end{aligned}$$

# Método de momentos

- Métodos de estimação mais simples e antigo.
- Seja,

$$m_r = \frac{1}{n} \sum_{i=1}^n X_i^r, \quad r \geq 1,$$

o  $r$ —ésimo momento amostral de uma a.a.  $X_1, X_2, \dots, X_n$ .

- Seja,

$$\mu_r = E(X^r), \quad r \geq 1,$$

o  $r$ —ésimo momento populacional.

# Método de momentos

- O método dos momentos consiste na obtenção de estimadores para  $\theta = (\theta_1, \theta_2, \dots, \theta_k)$  resolvendo o sistema de equações, ou seja,

$$\begin{aligned}\mu_1 = E(X) &= \frac{1}{n} \sum_{i=1}^n X_i = m_1 \\ \mu_2 = E(X^2) &= \frac{1}{n} \sum_{i=1}^n X_i^2 = m_2 \\ &\vdots \\ \mu_r = E(X^r) &= \frac{1}{n} \sum_{i=1}^n X_i^r = m_r\end{aligned}$$

# Exemplo

**Exemplo 11** Suponha que o tempo de vida de um determinado aparelho eletrônico é uma v.a. com distribuição exponencial de parâmetro  $\theta$ . Afim de estimar o valor de  $\theta$ , uma amostra de 20 aparelhos foi submetida a testes e registrou-se seus tempos de vida (em anos):

2; 4; 4; 6; 4; 5; 3, 5; 4, 5; 3, 5; 3; 5; 5; 4, 5; 2; 5; 3, 5; 3; 3, 5; 4, 5 e 4.

Obtenha uma estimativa para  $\theta$  pelo método dos momentos.

**Sol.** Temos que  $(X_1, \dots, X_n)$  é uma a.a. com  $X \sim \text{Exp}(\theta)$ . Pelo método dos momentos, temos de resolver a equação:

$$\mu_1 = E(X) = \frac{1}{n} \sum_{i=1}^n X_i = m_1$$

sabemos que se  $X \sim \text{Exp}(\theta)$ , então  $E(X) = 1/\theta$ , logo,

$$1/\theta = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}.$$

# O método de mínimos quadrados

- Quando dispomos uma uma relação de proporcionalidade entre duas variáveis  $X$  e  $Y$  usando a seguinte equação,

$$Y \approx \theta X$$

em que  $\theta$  é o coeficiente de proporcionalidade.

- Uma estratégia para se obter estimativas para o parâmetro  $\theta$  se dá através do método de mínimos quadrados.

# Método de mínimos quadrados

- Assim, devemos procurar a estimativa que torne esta soma de quadrados mínima. Ou seja, queremos encontrar o valor de  $\theta$  que minimiza a função

$$S(\theta) = \frac{d}{d\theta} \sum (Y - \theta X)^2 = \sum 2(Y - \hat{\theta} X)(-X) = 0$$

$$\sum (-2XY + \hat{\theta} 2X^2) = 0 \Rightarrow -2 \sum XY + 2\hat{\theta} \sum X^2 = 0$$

$$\hat{\theta} \sum X^2 = \sum XY \Rightarrow \hat{\theta} = \frac{\sum XY}{\sum X^2}.$$

Temos que  $\hat{\theta}$  é o estimador pelo método de momentos.

# Exemplo

**Exemplo 12** Um engenheiro está estudando a resistência  $Y$  de uma fibra em função de seu diâmetro  $X$ , e descobriu que as variáveis são aproximadamente proporcionais, isto é, elas obedecem à relação

$$Y \approx \theta X.$$

Uma amostra de 5 fibras foi obtida e submetida a testes, que forneceram os resultados:

$$X : 1.2 \quad 1.5 \quad 1.7 \quad 2.0 \quad 2.6 \quad \bar{X} = 1.8$$

$$Y : 3.9 \quad 4.7 \quad 5.6 \quad 5.8 \quad 7.0 \quad \bar{Y} = 5.4$$

# Exemplo

Usando os dados temos que

$$\sum XY = 51.05 \text{ e } \sum X^2 = 17.34$$

Assim, a estimativa do parâmetro de proporcionalidade pelo método de mínimos quadrados é dada por

$$\hat{\theta} \sum X^2 = \sum XY \Rightarrow \hat{\theta} = \frac{\sum XY}{\sum X^2} = \frac{51.05}{17.34} = 2.94.$$