

# Inferência Estatística I

## Métodos de estimação - Programação

---



**Prof. Paulo Cerqueira Jr**  
**Faculdade de Estatística - FAEST**  
**Instituto de Ciências Exatas e Naturais - ICEN**

<https://github.com/paulocerqueirajr> 

# Introdução

# Introdução

- Nessa unidade estaremos interessados no seguinte:

Problema 1: Seja  $f : \Theta \rightarrow \mathbb{R}$ . Encontre um ponto  $\theta \in \Theta$  que minimiza a função  $f$ .

- É importante observar que o problema de encontrar um ponto  $\theta \in \Theta$  que maximiza uma função  $g : \Theta \rightarrow \mathbb{R}$ , recai no problema anterior, basta ver que maximizar  $g$  é o mesmo que minimizar  $f = -g$ .
- Problemas de otimização (ou seja, de minimização ou maximização) ocorrem com frequência em diversas áreas das Ciências Exatas, em particular, na Estatística.

# Método de Newton-Raphson

# Caso unidimensional - Descrição do Método.

- O método de Newton-Raphson é um algoritmo apropriado para encontrar raízes (ou zeros) de funções.
- Formalmente, estamos interessados em encontrar um ponto  $\hat{\theta}$  no domínio de uma função  $h : \Theta \rightarrow \mathbb{R}$  tal que  $h(\hat{\theta}) = 0$ .
- Inicialmente vamos considerar o caso onde  $f$  é uma função de uma única variável.

# Newton-Raphson para Otimização

# Newton-Raphson para Otimização

- Considere o problema 1 para o caso em que  $f$  é uma função de uma única variável.
- O método de Newton-Raphson é apropriado para resolver numericamente este problema de otimização, basta encontrar as raízes de  $h = f'$ .
- Neste caso o mínimo  $\theta$  pode ser encontrado seguindo os seguintes passos:
  1. Fixe um número real  $\epsilon > 0$ ;
  2. Dê uma aproximação inicial  $\theta_0$  para  $\hat{\theta}$ ;
  3. Para  $k \geq 0$ , faça

$$\theta_{k+1} = \theta_k - \frac{f'(\theta_k)}{f''(\theta_k)}.$$

4. Pare o processo iterativo se  $|\theta_{k+1} - \theta_k| < \epsilon$ . Caso contrário, volte para o passo anterior.

# Exemplo

Utilize o método de Newton-Raphson para encontrar o mínimo da função  $f(\theta) = \theta^2 - \sin(\theta)$ .


Solução:

- Fixe  $\epsilon = 0,0001$  e  $\theta_0 = \pi/8$ , itere e para  $k \geq 0$

$$\begin{aligned}\theta_{k+1} &= \theta_k - \frac{f'(\theta_k)}{f''(\theta_k)} \\ &= \theta_k - \frac{2\theta_k - \cos(\theta_k)}{2 + \sin(\theta_k)}\end{aligned}$$



# Exemplo:



- O R também possui funções prontas para pesquisar, dentro de um intervalo, um ponto de mínimo (ou de máximo) de uma função.
- Veja o código abaixo aplicado para o exemplo em questão:

```
1 optimize(f, c(0,pi/4),  
2          tol=0.000001) # Otimização
```

\$minimum  
[1] 0.4501836

\$objective  
[1] -0.2324656

# Newton-Raphson em Estatística

# Newton-Raphson em Estatística

- Seja  $(X_1, \dots, X_n)$  uma a.a. de tamanho  $n$  da distribuição de uma v.a.  $X$  com densidade  $f(x; \theta)$  onde  $\theta$  pertence ao espaço paramétrico  $\Theta$  (por enquanto, considere que  $\Theta$  é unidimensional).
- A função de verossimilhança de  $\theta$  ( $L : \Theta \rightarrow \mathbb{R}$ ) associada à a.a. observada  $\mathbf{x} = (x_1, \dots, x_n)$  é definida por

$$L(\theta) = L(\theta, \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta)$$

- Seja a função de log verossimilhança dada por:

$$\ell(\theta) = \ln(L(\theta)).$$

e a função escore:

$$U(\theta) = \frac{d \ln L(\theta)}{d\theta} = \frac{d\ell(\theta)}{d\theta} = \ell'.$$

# Newton-Raphson em Estatística

- Portanto o estimador de máxima verossimilhança, denotado por  $\hat{\theta}$ , satisfaz as seguintes equações:

$$U(\hat{\theta}) = 0 \quad \Rightarrow \quad \hat{\theta} = \max_{\theta \in \Theta} \ell(\theta).$$

- Em alguns casos pode ser difícil obter uma solução analítica explícita para as equações.
- Nesses casos, é possível obter uma solução aproximada para  $\hat{\theta}$  por meio de métodos numéricos.
- Uma alternativa consiste em utilizar o método de Newton-Raphson para aproximar a raiz da função escore (ou maximizar a logverossimilhança).

# Newton-Raphson em Estatística

- Explicitamente, basta seguir o seguinte algoritmo:

1. Fixe um número real  $\epsilon > 0$ ;
2. Dê uma aproximação inicial  $\theta_0$  para  $\hat{\theta}$ ;
3. Para  $k \geq 0$ , faça

$$\theta_{k+1} = \theta_k - \frac{U(\theta_k)}{U'(\theta_k)} = \theta_k - \frac{\ell'(\theta_k)}{\ell''(\theta_k)}.$$

4. Pare o processo iterativo se  $|\theta_{k+1} - \theta_k| < \epsilon$ . Caso contrário, volte para o passo anterior.

- A sequência  $(\theta_k)_{k \geq 0}$  converge para  $\hat{\theta}$  quando  $k \rightarrow \infty$ , se  $\theta_0$  é escolhido próximo de  $\hat{\theta}$

(Dica: um gráfico de  $U(\theta)$  ou  $\ell(\theta)$  pode ajudar nessa escolha inicial).

# Método Escore

# Método Escore

- Em alguns casos, a substituição de  $U'(\theta_k)$  por  $E(U'(\theta_k))$ , apresenta significativa simplificação no procedimento.
- Esse método é conhecido como método do escore e pode ser descrito assim:

1. Fixe um número real  $\epsilon > 0$ ;
2. Dê uma aproximação inicial  $\theta_0$  para  $\hat{\theta}$ ;
3. Para  $k \geq 0$ , faça

$$\theta_{k+1} = \theta_k - \frac{U(\theta_k)}{E(U'(\theta_k))} = \theta_k - \frac{U(\theta_k)}{I(\theta_k)}.$$

em que  $I(\theta_k)$  é a informação de Fisher de  $\theta$ .

4. Pare o processo iterativo se  $|\theta_{k+1} - \theta_k| < \epsilon$ . Caso contrário, volte para o passo anterior.
- Novamente, a sequência  $(\theta_k)_{k \geq 0}$  converge para  $\hat{\theta}$  quando  $k \rightarrow \infty$ , se  $\theta_0$  é escolhido próximo de  $\hat{\theta}$ .

# Exemplo

Sejam  $X_1, \dots, X_n$  uma a.a. de  $X$ , com função densidade dada por

$$f(x \mid \theta) = \frac{1}{2} (1 + \theta x), \quad -1 \leq x \leq 1, \quad -1 \leq \theta \leq 1.$$

Determine o EMV para  $\theta$  pelo método de Newton-Raphson e Escore.

Sol. Inicialmente temos que a função de verossimilhança é dada por

$$L(x \mid \theta) = \frac{1}{2^n} \prod_{i=1}^n (1 + \theta x_i),$$

de modo que

$$U(\theta) = \ell' = \sum_{i=1}^n \frac{x_i}{1 + \theta x_i}$$



# Exemplo

E dessa forma

$$U'(\theta) = \ell'' = - \sum_{i=1}^n \frac{x_i^2}{(1 + \theta x_i)^2}.$$

A informação de Fisher de  $\theta$  é igual,

$$I(\theta) = \frac{1}{2\theta^3} \left\{ \log \left( \frac{1 + \theta}{1 - \theta} \right) - 2\theta \right\}.$$

Gerou-se  $n = 20$  valores, com  $\theta = 0.4$  usando a função densidade do exemplo via método da transformação inversa, logo


$$x = \frac{-1 + 2\sqrt{1/4 - \theta(1/2 - \theta/4 - u)}}{\theta}.$$

em que  $U \sim U(0, 1)$ .

# Exemplo


- Código em R:

```
1 set.seed(123456)
2 n <- 200
3 theta <- 0.4
4 u <- runif(n, 0, 1)
5 raiz <- 1 - (theta * (2 - theta)) + (4 * the
6 dados <- (-1 + sqrt(raiz)) / (theta)
```




# Exemplo

Log-verossimilhança



Função escore



# Exemplo - Comparação dos métodos:

## Newton-Raphson:

```
1 theta.zero <- 0.15
2 precisao <- 0.000001
3 dif <- 1
4 while(dif > precisao){
5   num <- S(theta.zero)
6   den <- S.prime(theta.zero)
7   theta.um <- theta.zero - (num/den)
8   dif <- abs(theta.um - theta.zero)
9   theta.zero <- theta.um
10  print(theta.zero)
11 }
```

```
[1] 0.3459363
[1] 0.3398386
[1] 0.3398224
[1] 0.3398224
```

```
1 raiz.NR <- theta.zero
2 raiz.NR # Método NR.
```

```
[1] 0.3398224
```

## Escore:

```
1 theta.zero <- 0.15
2 dif <- 1
3 while(dif > precisao){
4   num <- S(theta.zero)
5   a <- 2*theta.zero
6   b <- log((1+theta.zero)/(1-theta.
7   den <- n*(1/(2*theta.zero^3))*b
8   theta.um <- theta.zero + (num/den)
9   dif <- abs(theta.um - theta.zero)
10  theta.zero <- theta.um
11  print(theta.zero)
12 }
```

```
[1] 0.3433802
[1] 0.3397711
[1] 0.3398231
[1] 0.3398223
```

```
1 raiz.E <- theta.zero
2 raiz.E # Método Escore
```

```
[1] 0.3398223
```

# Caso Multidimensional

# Método de Newton-Raphson

- Agora considere o problema de otimização quando  $\Theta$  é um espaço multidimensional.
- Antes de apresentar o método de Newton-Raphson nesse caso, vejamos alguns conceitos básicos de Cálculo.

Noções preliminares:

Seja  $n$  um inteiro positivo e seja  $D \subseteq \mathbb{R}^n$ . Considere uma função  $g$  que associa a cada  $\mathbf{x} = (x_1, \dots, x_n) \in D$  um número real  $g(\mathbf{x})$ , ou seja,  $g : D \rightarrow \mathbb{R}$ . O gradiente de  $g$ , denotado por

$$\nabla g(\mathbf{x}) = \left( \frac{\partial g}{\partial x_1}, \dots, \frac{\partial g}{\partial x_n} \right).$$

# Método de Newton-Raphson

- Seja  $(X_1, \dots, X_n)$  uma a.a. de tamanho  $n$  da distribuição de uma v.a.  $X$  com densidade  $f(x; \theta)$  onde  $\theta = (\theta_1, \dots, \theta_n)$  pertence ao espaço paramétrico  $\Theta$ .
- A função de verossimilhança de  $\theta$  ( $L : \Theta \rightarrow \mathbb{R}$ ) associada à a.a. observada  $\mathbf{x} = (x_1, \dots, x_n)$  é definida por

$$L(\theta) = L(\theta, \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta)$$

- Seja a função de log verossimilhança dada por:

$$\ell(\theta) = \ln(L(\theta)).$$

# Método de Newton-Raphson

- O  $i$ -ésimo elemento do vetor escore, denotado por  $U(\theta)$ , é dado por

$$U_i(\theta) = \frac{\partial \ell(\theta)}{\partial \theta^{(i)}}.$$

- O  $(i, j)$ -elemento da matriz Hessiana, denotada por  $H(\theta)$ , é dado por

$$H_{ij} = \frac{\partial^2 \ell}{\partial \theta^{(i)} \partial \theta^{(j)}}.$$

Portanto o estimador de máxima verossimilhança, denotado por  $\hat{\theta}$ , satisfaz as seguintes equações:

$$U(\hat{\theta}) = \nabla \ell(\hat{\theta}) = \mathbf{0} \quad \hat{\theta} = \arg \max_{\theta \in \Theta} \ell(\theta).$$



# Newton-Raphson em Estatística

- Em alguns casos pode ser difícil obter uma solução analítica explícita para as equações.
- Nesses casos, é possível obter uma solução aproximada para  $\hat{\theta}$  por meio de métodos numéricos.
- Um alternativa consiste em utilizar o método de Newton-Raphson para aproximar a raiz da função escore (ou maximizar a logverossimilhança).

# Newton-Raphson em Estatística

- Explicitamente, basta seguir o seguinte algoritmo:

1. Fixe um número real  $\epsilon > 0$ ;
2. Dê uma aproximação inicial  $\theta_0$  para  $\hat{\theta}$ ;
3. Para  $k \geq 0$ , faça

$$\theta_{k+1} = \theta_k - [H(\theta_k)]^{-1}U(\theta_k).$$

4. Pare o processo iterativo se  $|\theta_{k+1} - \theta_k| < \epsilon$ . Caso contrário, volte para o passo anterior.
- A sequência  $(\theta_k)_{k \geq 0}$  converge para  $\hat{\theta}$  quando  $k \rightarrow \infty$ , se  $\theta_0$  é escolhido próximo de  $\hat{\theta}$

# Método Escore

- Por vezes substituir de  $H(\theta_k)$  por  $E(H(\theta_k))$  pode apresentar significativa simplificação no procedimento.
- Esse método é conhecido como método do escore e pode ser descrito assim:

1. Fixe um número real  $\epsilon > 0$ ;
2. Dê uma aproximação inicial  $\theta_0$  para  $\hat{\theta}$ ;
3. Para  $k \geq 0$ , faça

$$\theta_{k+1} = \theta_k - [E(H(\theta_k))]^{-1}U(\theta_k) = \theta_k - [-I(\theta_k)]^{-1}U(\theta_k),$$

onde  $I(\theta_k)$  é a matriz de informação de Fisher de  $\theta$ .

4. Pare o processo iterativo se  $|\theta_{k+1} - \theta_k| < \epsilon$ . Caso contrário, volte para o passo anterior.
- A sequência  $(\theta_k)_{k \geq 0}$  converge para  $\hat{\theta}$  quando  $k \rightarrow \infty$ , se  $\theta_0$  é escolhido próximo de  $\hat{\theta}$